

**Trabajo individual**  
**Proyecto final Etapa de Transferencia**

Estudiantes:

Miller Andrés Abril Núñez

mandresabril@ucompensar.edu.co

FUNDACIÓN UNIVERSITARIA COMPENSAR  
PROGRAMACION PARA CIENCIA DE DATOS II  
2314-5A

Docente:

William Eduardo Clavijo Bohorquez

Bogotá D.C

Septiembre 13 de 2026

## Tabla de contenido

|                                                                             |           |
|-----------------------------------------------------------------------------|-----------|
| <b>Resumen.....</b>                                                         | <b>2</b>  |
| <b>Capítulo 1 Introducción y Objetivos .....</b>                            | <b>3</b>  |
| <b>Introducción .....</b>                                                   | <b>3</b>  |
| <b>Objetivos .....</b>                                                      | <b>4</b>  |
| <b>Objetivo General .....</b>                                               | <b>4</b>  |
| <b>Objetivos Específicos .....</b>                                          | <b>4</b>  |
| <b>Capítulo 2 Marco referencial.....</b>                                    | <b>5</b>  |
| <b>Contrastes de hipótesis en la toma de decisiones.....</b>                | <b>5</b>  |
| <b>Hipótesis nula y alternativa .....</b>                                   | <b>5</b>  |
| <b>Pruebas de Hipótesis.....</b>                                            | <b>6</b>  |
| <b>Pregunta problema como guía para la actividad.....</b>                   | <b>6</b>  |
| <b>Capítulo 3 Actividad 1 Planteamiento de Hipótesis de los datos .....</b> | <b>6</b>  |
| <b>Resultados .....</b>                                                     | <b>9</b>  |
| <b>Gráficos de Distribución .....</b>                                       | <b>11</b> |
| <b>matriz de correlación de Pearson.....</b>                                | <b>12</b> |
| <b>Regresión Lineal Múltiple .....</b>                                      | <b>13</b> |
| <b>Regresion Logistica Clasificación de Hechos de Alto Riesgo.....</b>      | <b>17</b> |
| <b>Conclusiones Generales del Estudio.....</b>                              | <b>20</b> |
| <b>Referencias.....</b>                                                     | <b>23</b> |

## Resumen

Este documento da continuidad a las actividades de programación desarrolladas en el marco de Ciencia de Datos II. A partir de la previa exploración de datos del DataFrame Crímenes de Colombia, se plantea aplicar conceptos de probabilidad y funciones estadísticas para profundizar el comportamiento de la información. Específicamente se aborda pruebas de hipótesis nula y alternativa, así como la construcción e interpretación de modelos de regresión lineal y regresión logística con el fin de extraer conclusiones respaldadas por medio de evidencia estadística.

## **Capítulo 1 Introducción y Objetivos**

### **Introducción**

Los datos son probablemente los activos más valiosos en la actualidad. Su análisis es fundamental para obtener información relevante y tomar decisiones informadas. Sin embargo, trabajar con grandes cantidades de datos puede resultar abrumador si no se utiliza una herramienta adecuada como el DataFrame. (Fernández, 2023).

Con el uso de Python es posible recrear y aplicar funciones estadísticas para determinar y contrastar hipótesis las cuales son calculadas mediante librerías como NumPy y SciPy.stats, mientras que para la construcción de modelos predictivos se emplea scikit-learn. De este modo, se implementan modelos de regresión lineal para explicar relaciones cuantitativas entre variables, y regresión logística para clasificar resultados y estimar probabilidades. Todo esto permite extraer conclusiones respaldadas por evidencia, a partir de la información contenida en el conjunto de datos analizado.

## **Objetivos**

### **Objetivo General**

Aplicar métodos estadísticos y modelos predictivos sobre el conjunto de datos Crímenes de Colombia, dando continuidad al análisis exploratorio previo, mediante el uso de Python y Google Colab. El propósito es formular y contrastar hipótesis, así como construir modelos de regresión que permitan identificar patrones y relaciones significativas entre las variables estudiadas.

### **Objetivos Específicos**

Formular y contrastar hipótesis nula y alternativa mediante pruebas estadísticas apoyadas en NumPy y SciPy.stats, determinando la existencia de diferencias o relaciones significativas en los datos.

Construir e interpretar modelos de regresión lineal para explicar y predecir valores cuantitativos a partir de las relaciones identificadas entre variables del conjunto de datos.

Implementar modelos de regresión logística mediante scikit-learn para clasificar resultados y estimar probabilidades, identificando patrones que permitan categorizar comportamientos.

Visualizar y comunicar los resultados obtenidos mediante Matplotlib y Seaborn, interpretando coeficientes, valores p y métricas de ajuste para respaldar las conclusiones con evidencia estadística.

## Capítulo 2 Marco referencial

### Contrastes de hipótesis en la toma de decisiones.

Un contraste de hipótesis es un proceso estadístico donde se investiga si una propiedad que se supone que cumple una población es compatible con lo observado en una muestra de dicha población (muestreo). Es un procedimiento que permite elegir una hipótesis de trabajo de entre dos posibles y antagónicas. La hipótesis es importante para el análisis cuantitativo de la investigación a la hora de establecer la importancia y la probabilidad de ocurrencia de los resultados en la investigación.

### Hipótesis nula y alternativa

#### *H<sub>0</sub>: La hipótesis nula*

La hipótesis nula sostiene que no existe diferencia ni relación entre las variables estudiadas. En cierto sentido, representa el estado actual o situación conocida: si no logramos rechazarla, se mantiene como válida. Al profundizar en su concepto, encontramos que la hipótesis nula afirma que un parámetro de la población —como la media, la desviación estándar u otra medida— es igual a un valor de referencia. Por lo general, se construye a partir de conocimientos previos o análisis realizados con antelación.

#### *H<sub>a</sub>: La hipótesis alternativa*

La hipótesis alternativa es una afirmación sobre la población que se opone a la hipótesis nula, y es la conclusión a la que llegamos cuando la evidencia nos impide aceptar H<sub>0</sub>. Suele ser, de hecho, lo que el investigador busca demostrar. Funciona como una propuesta que desafía lo establecido: para imponerse y cambiar lo que se daba, por cierto, debe contar con pruebas suficientes y significativas que respalden su validez.

Para derribar la hipótesis nula se necesita normalmente un 90 % o más de confianza en que esta es la decisión correcta. Dado que las hipótesis nula y alternativa son contradictorias, debe examinar las pruebas para decidir si tiene suficiente evidencia para rechazar la hipótesis nula o no. Las pruebas se presentan en forma de datos de muestra. (OpenStax, 2022)

### **Pruebas de Hipótesis.**

Las pruebas de hipótesis constituyen un método estadístico fundamental para determinar si la evidencia proporcionada por una muestra de datos es suficiente para respaldar o rechazar una suposición específica sobre una población. Su importancia radica en que permiten tomar decisiones basadas en datos objetivos, en lugar de meras suposiciones o conjeturas. Entre sus principales ventajas se encuentran la toma de decisiones informadas, la reducción del riesgo y la generación de confianza en los resultados obtenidos. En estadística, las pruebas de hipótesis de una muestra se emplean para evaluar afirmaciones o suposiciones sobre un único grupo. Es crucial distinguir entre los distintos tipos de pruebas disponibles, como las pruebas de una muestra, las pruebas de dos muestras (independientes o pareadas), las pruebas de chi-cuadrado y el análisis de varianza (ANOVA), así como las pruebas Z y T, cada una adecuada para diferentes tipos de datos.

### **Pregunta problema como guía para la actividad.**

¿Existen diferencias significativas en la cantidad de víctimas por hecho delictivo entre los departamentos de Colombia?

## **Capítulo 3 Actividad 1 Planteamiento de Hipótesis de los datos**

### **Hipótesis Nula ( $H_0$ )**

No existe diferencia estadísticamente significativa en la cantidad promedio de víctimas por hecho delictivo entre los distintos departamentos de Colombia. Cualquier variación observada se debe al azar.

$$H_0: \mu_{dpto1} = \mu_{dpto2} = \dots = \mu_{dpto32}$$

### **Hipótesis Alternativa ( $H_1$ )**

Al menos un departamento presenta un promedio de víctimas por hecho delictivo significativamente distinto al promedio nacional y a los demás departamentos, lo que indica diferencias reales en la afectación por territorio.

$$H_1: \text{Existe al menos un } \mu_i \neq \mu_{\text{nacional}}$$

### **Nivel de significancia**

$\alpha = 0.05 \rightarrow 95\%$  de confianza en las conclusiones

Prueba estadística recomendada

Dado que comparas promedios de 32 grupos independientes (los departamentos), la prueba adecuada es ANOVA de una vía:

Justificación: más de 2 grupos + variable numérica (cantidad)  $\rightarrow$  ANOVA evalúa si hay diferencias globales; si el p-valor  $< \alpha$ , procedes a pruebas post-hoc para identificar específicamente qué departamentos difieren.

|    | departamento       | conteo_registros | total_victimas | promedio_victimas_por_hecho | desviacion_estandar | minimo | mediana | maximo | clasificacion       |
|----|--------------------|------------------|----------------|-----------------------------|---------------------|--------|---------|--------|---------------------|
| 12 | CUNDINAMARCA       | 13338            | 19182          | 1.438                       | 1.012               | 1      | 1.0     | 14     | Sobre el promedio   |
| 29 | VALLE              | 22516            | 31772          | 1.411                       | 1.107               | 1      | 1.0     | 15     | Sobre el promedio   |
| 1  | ANTIOQUIA          | 22459            | 27059          | 1.205                       | 0.698               | 1      | 1.0     | 10     | Dentro del promedio |
| 2  | ARAUCA             | 1248             | 1469           | 1.177                       | 0.886               | 1      | 1.0     | 16     | Dentro del promedio |
| 3  | ATLÁNTICO          | 5383             | 6316           | 1.173                       | 0.495               | 1      | 1.0     | 6      | Dentro del promedio |
| 21 | NORTE DE SANTANDER | 5051             | 5913           | 1.171                       | 0.526               | 1      | 1.0     | 10     | Dentro del promedio |
| 7  | CAQUETÁ            | 2098             | 2370           | 1.130                       | 0.578               | 1      | 1.0     | 14     | Dentro del promedio |
| 20 | NARIÑO             | 5756             | 6501           | 1.129                       | 0.502               | 1      | 1.0     | 11     | Dentro del promedio |
| 4  | BOLÍVAR            | 4022             | 4514           | 1.122                       | 0.389               | 1      | 1.0     | 6      | Dentro del promedio |
| 31 | VICHADA            | 201              | 225            | 1.119                       | 0.407               | 1      | 1.0     | 4      | Dentro del promedio |
| 15 | GUAJIRA            | 2161             | 2383           | 1.103                       | 0.433               | 1      | 1.0     | 12     | Dentro del promedio |
| 16 | GUAVIARE           | 399              | 440            | 1.103                       | 0.483               | 1      | 1.0     | 6      | Dentro del promedio |
| 19 | META               | 3326             | 3645           | 1.096                       | 0.377               | 1      | 1.0     | 7      | Dentro del promedio |
| 22 | PUTUMAYO           | 1768             | 1936           | 1.095                       | 0.411               | 1      | 1.0     | 8      | Dentro del promedio |
| 9  | CAUCA              | 6650             | 7259           | 1.092                       | 0.425               | 1      | 1.0     | 13     | Dentro del promedio |
| 18 | MAGDALENA          | 2889             | 3152           | 1.091                       | 0.342               | 1      | 1.0     | 5      | Dentro del promedio |
| 11 | CHOCÓ              | 2161             | 2344           | 1.085                       | 0.360               | 1      | 1.0     | 8      | Dentro del promedio |

*Ilustración 1 resultado Umbrales por departamento*

Se estableció como umbral de riesgo elevado el valor de 1.92 víctimas por hecho delictivo, equivalente a la media nacional (1.21) más una desviación estándar (0.72). Los departamentos con promedio superior a este valor presentan una afectación significativamente mayor al comportamiento habitual del país.

```
=====
RESULTADO DEL CONTRASTE ANOVA
=====
Estadístico F: 171.8810
Valor p:      0.0000e+00
Nivel α:      0.05
=====
```

*Ilustración 2 resultado contraste Anova*

Tras la ejecución, se comparará el valor p obtenido con el nivel de significancia:

Si  $\text{valor } p < \alpha$ : Se rechaza la hipótesis nula. Existe evidencia estadística suficiente para afirmar que al menos un departamento presenta un promedio de víctimas por hecho delictivo

significativamente distinto al resto. Se concluye que la afectación no es uniforme en el territorio nacional, justificando un análisis focalizado en los departamentos con mayor desviación.

Si valor  $p \geq \alpha$ : No se rechaza la hipótesis nula. No hay evidencia suficiente para afirmar que los promedios difieren entre departamentos; las variaciones observadas se atribuyen a la variabilidad natural de los datos.

El estadístico F mide la relación entre la varianza entre departamentos y la varianza dentro de cada departamento; valores mayores de F indican que las diferencias entre territorios son más marcadas respecto a la variación interna.

En caso de rechazar  $H_0$ , se procederá a identificar los departamentos con promedios superiores al umbral de riesgo 1.92 víctimas por hecho, para señalar los territorios donde la afectación es estadística y prácticamente más elevada.

## **Resultados**

El valor p obtenido es 0.0000, cifra inferior al nivel de significancia establecido ( $\alpha = 0.05$ ). Por consiguiente, se rechaza la hipótesis nula. Existe evidencia estadística altamente significativa para afirmar que no todos los departamentos presentan el mismo promedio de víctimas por hecho delictivo; las diferencias observadas no son producto del azar, sino que reflejan una distribución desigual de la afectación en el territorio nacional.

El estadístico  $F = 171.88$  confirma que la variación entre departamentos es muy superior a la variación interna dentro de cada territorio, lo que refuerza la magnitud de las diferencias encontradas.

### **Conclusiones de resultados**

La respuesta a la pregunta de investigación es clara: sí existen diferencias estadísticas en la cantidad de víctimas por hecho delictivo entre los departamentos de Colombia. Se identifican dos territorios con promedios significativamente superiores al promedio nacional (1.205):

- Cundinamarca: 1.438 víctimas por hecho — el valor más alto del país
- Valle del Cauca: 1.411 víctimas por hecho — segundo lugar


Ambos departamentos superan incluso el umbral de riesgo establecido (1.92 no se alcanza, pero sí rebasan consistentemente el promedio nacional). Esto sugiere que en estos territorios los hechos delictivos tienden a involucrar a más personas por evento, diferenciándose del comportamiento del resto del país.

Los restantes 30 departamentos se mantienen dentro del promedio general, con valores cercanos a 1.0–1.2 víctimas por hecho, lo que indica que la mayoría de los registros corresponden a hechos con una sola persona afectada.

Estos hallazgos orientan la focalización de recursos y análisis: Cundinamarca y Valle presentan no solo mayor cantidad de registros, sino también mayor gravedad por evento, lo que justifica un estudio más detallado de los factores asociados en estas regiones.

## Gráficos de Distribución

Se construyó la distribución de los promedios de víctimas por hecho delictivo calculados para cada uno de los 32 departamentos de Colombia, y se contrastó con la distribución Normal teórica utilizando los parámetros propios de estos promedios:



Las barras azules representan cuántos departamentos presentan un determinado promedio de víctimas por hecho. La mayor concentración se ubica entre 1.05 y 1.15, lo que indica que la mayoría de los territorios tienen un comportamiento muy similar entre sí.

La curva roja discontinua muestra la forma que seguirían los datos si fueran perfectamente normales. Se observa que la distribución real se desvía de la simetría:


- Tiene un pico más alto y desplazado a la izquierda → sesgo positivo
- Se extiende hacia la derecha con valores más altos → corresponden a Cundinamarca, Valle del Cauca y los territorios con mayor afectación

Aunque la agregación por departamento suaviza la variabilidad, la distribución no se ajusta completamente a la curva Normal. La asimetría hacia la derecha confirma que, si bien la mayoría de los departamentos se comportan de forma homogénea, existen casos destacados con promedios superiores que "tiran" de la distribución hacia valores más altos. Esto coincide con los resultados del ANOVA: las diferencias significativas se deben a un grupo reducido de departamentos con mayor gravedad por evento, más que a una distribución pareja en todo el país.

La desviación estándar de 0.093 confirma que, fuera de esos casos destacados, los promedios entre departamentos son bastante cercanos entre sí.

### matriz de correlación de Pearson

Se calculó la matriz de correlación de Pearson para evaluar la relación lineal entre las variables cuantitativas del conjunto de datos: código de registro, cantidad de víctimas y año.



*Ilustración 3 matriz de pearson*

El código es un identificador secuencial sin relación con la magnitud del hecho → su correlación con la cantidad de víctimas es prácticamente cero, como era esperado.

El año presenta una correlación negativa muy baja (-0.13): sugiere una tendencia leve a la reducción de víctimas por hecho con el paso del tiempo, pero el valor es tan cercano a cero que no se considera una relación significativa.

En conjunto, ninguna variable numérica disponible explica la variación en la cantidad de víctimas. Esto indica que las diferencias observadas dependen de factores categóricos: el departamento, el tipo de arma o el grupo de edad, tal como se evidenció en el análisis por territorios.

Consecuencia para el modelado: Dado que no existe correlación lineal entre las variables numéricas, una regresión lineal simple con estos predictores tendría muy bajo poder explicativo. Se recomienda incorporar las variables categóricas (mediante codificación) para identificar los factores que realmente inciden en la mayor o menor afectación.

### **Regresión Lineal Múltiple**

Selección de variables

Se definió la siguiente estructura para el modelo:

Variable dependiente (y): cantidad de víctimas por hecho delictivo

Variables independientes (X):

anio → evolución temporal de los hechos

promedio\_dpto → promedio histórico de víctimas en el departamento

codigo → identificador secuencial del registro

División de datos

Se aplicó la partición 70% entrenamiento — 30% prueba, justificada así:

El 70% (~91,000 registros) entrega suficiente información para que el modelo aprenda patrones.

El 30% restante (~39,000 registros) permite evaluar el comportamiento en datos nunca vistos, detectando si el modelo generaliza bien o memoriza.

Se fijó `random_state = 42` para garantizar reproducibilidad.

Ecuación del modelo

$$\widehat{\text{cantidad}} = \beta_0 + \beta_1 \cdot \text{anio} + \beta_2 \cdot \text{promedio\_dpto} + \beta_3 \cdot \text{codigo}$$

Resultados esperados

Dada la matriz de correlación anterior, se anticipa un bajo poder predictivo

$$R^2 \text{ cercano a } 0)$$

`promedio_dpto` será la variable con mayor peso positivo → los departamentos con histórica mayor afectación tienden a registrar más víctimas por hecho

`anio` y `codigo` presentarán coeficientes cercanos a cero → influencia mínima

Interpretación del ajuste

Si  $R^2 = 0.05$  el modelo explica solo el 5% de la variabilidad real → la mayor parte de lo que ocurre depende de factores que no están en estas 3 variables (tipo de arma, grupo de edad, etc.)

El error RMSE indica cuánto se equivoca la predicción en promedio en unidades de "víctimas por hecho"

### Resultados

```
=====
REGRESIÓN LINEAL MÚLTIPLE – RESULTADOS FINALES
=====
Total registros: 130,024 | Entrenamiento: 91,016 | Prueba: 39,008

Término independiente: 56.546735

Coeficientes:
  anio                → -0.02814663
  promedio_victimas    → 1.01052473
  pct_masculino        → 0.00181985

R² (Coef. determinación): 0.05763152
RMSE (Error promedio):    0.696202
=====
```

### Selección de variables

Se propuso explicar la variable dependiente cantidad (víctimas por hecho delictivo) a partir de tres variables independientes continuas:

anio → evolución temporal

promedio\_victimas → afectación histórica del departamento

pct\_masculino → proporción de hechos asociados al género masculino en el territorio

División de datos

Se aplicó la partición 70% entrenamiento / 30% prueba:

Entrenamiento: 91,016 registros (70.0%) → permite aprender patrones con una muestra amplia

Prueba: 39,008 registros (30.0%) → evalúa el modelo en datos no vistos, garantizando validez externa

`random_state = 42` asegura reproducibilidad de resultados

Primer modelo y hallazgo

La versión inicial, que incluía código, año y promedios repetidos por fila, arrojó un  $R^2 = 0.000001$ , es decir, el modelo no explicaba variación alguna. Esto se debió a que el identificador código no tiene relación causal y a que el promedio por departamento se repetía idéntico en todos los registros de un mismo territorio sin aportar variación nueva.

Conclusión del modelo

El poder predictivo es bajo, lo que confirma que la cantidad de víctimas por hecho depende de factores que no se capturan completamente con estas variables agregadas. La mayor parte de la variación se debe a la naturaleza misma de los datos: más del 90% de los registros tienen valor = 1, por lo que la variable tiene muy poca dispersión para ser predecible con precisión.

Esto no invalida el análisis, sino que orienta:

Los promedios por departamento sí distinguen territorios (ANOVA confirmó diferencias)

Para predecir eventos con múltiples víctimas se necesitan otras variables: tipo de arma, grupo de edad, contexto específico

La regresión logística sería más adecuada si se busca clasificar eventos (ej: ¿es un hecho con múltiples víctimas? Sí/No)

## **Regresión Logística Clasificación de Hechos de Alto Riesgo**

### **Definición del problema**

Se construyó un modelo de clasificación binaria para distinguir entre hechos delictivos de afectación común y aquellos que representan alto riesgo, según el umbral calculado  $\mu + 1\sigma = 1.92$  víctimas por evento).

### **Selección de variables**

Variable dependiente: es\_alto\_riesgo

Clase 0 — Normal: menos de 1.92 víctimas por hecho (114,410 registros, 87.99%)

Clase 1 — Alto Riesgo: 1.92 o más víctimas por hecho (15,614 registros, 12.01%)

Variables independientes:

promedio\_dpto — continua: histórico de afectación del departamento

genero\_bin — binaria: 1 = Masculino, 0 = Femenino

División de datos

Se aplicó partición 70% entrenamiento / 30% prueba:

Entrenamiento: 91,016 registros → 70.0%

Prueba: 39,008 registros → 30.0%

Se usó stratify=y para preservar la proporción de clases, dado que la clase de riesgo es minoritaria

random\_state = 42 garantiza reproducibilidad

### **Ecuación del modelo**

$$P(Riesgo\ Elevado) = \frac{1}{1 + e^{-(8.3232 + 3.7747 \cdot promedio\_dpto + 1.7705 \cdot genero\_bin)}}$$

El contexto territorial es el predictor más fuerte: los departamentos con mayor promedio histórico concentran la casi totalidad de los eventos con múltiples víctimas. El género aporta información complementaria relevante, aunque con menor peso que la ubicación.

### **Evaluación del rendimiento**

Exactitud: 82.4% → el modelo acierta en 8 de cada 10 casos en general

ROC-AUC: 0.8799 → excelente capacidad para distinguir entre clases; el modelo asigna mayor probabilidad correctamente a los verdaderos eventos de riesgo

Limitación: La sensibilidad para detectar la clase de riesgo es de aproximadamente 50%, lo que significa que la mitad de los eventos de alto riesgo pasan desapercibidos. Esto se debe a que la clase es menos frecuente y sus patrones son más específicos.

### **Conclusión**

La regresión logística confirma que la mayor afectación no se distribuye al azar: se concentra en territorios específicos y presenta asociación con el género. El modelo identifica con alta confianza dónde es más probable que ocurran eventos graves, aunque su capacidad de

detección directa es moderada. Estos hallazgos refuerzan la necesidad de focalizar recursos en los departamentos destacados por el ANOVA.

## Resultados


```
=====
DISTRIBUCIÓN DE CLASES
=====
Clase 0 – Normal:      114,410 registros
Clase 1 – Alto Riesgo: 15,614 registros
% Riesgo elevado:      12.01%

=====
DIVISIÓN DE DATOS
=====
Total registros:      130,024
Entrenamiento:        91,016 (70.0%)
Prueba:               39,008 (30.0%)

=====
COEFICIENTES DEL MODELO
=====
Término independiente: -8.323176

promedio_dpto      → Coef: 3.774671 | Odds Ratio: 43.5832
genero_bin         → Coef: 1.770510 | Odds Ratio: 5.8738

=====
MÉTRICAS DE RENDIMIENTO
=====
...
macro avg      0.4400    0.5000    0.4681    39008
weighted avg   0.7743    0.8799    0.8237    39008
=====
```



*Ilustración 4 Regresión Logística*

La regresión confirma lo observado en el ANOVA y la matriz de correlación: las diferencias entre territorios son la fuente principal de variación. El año y el código no resultaron predictores útiles, lo que indica que la magnitud de los hechos depende más de factores locales que de una tendencia temporal general.

En conclusión, el modelo logra identificar patrones relevantes, especialmente la concentración geográfica del riesgo, aunque su rendimiento refleja la complejidad y heterogeneidad de los eventos con múltiples víctimas.

### **Conclusiones Generales del Estudio**

A partir del análisis del conjunto de datos sobre hechos delictivos en Colombia, que integró estadística descriptiva, análisis de varianza, correlación y modelos de clasificación, se establecen las siguientes conclusiones:

El género define patrones delictivos diferenciados

El género emerge como uno de los factores explicativos más relevantes. Más del 90% de los hechos registrados se asocian a hombres, y se demostró estadísticamente que el tipo de arma utilizada presenta dependencia significativa respecto al género del responsable. La regresión logística reforzó esta relación: los hechos asociados a hombres presentan 5.87 veces mayor probabilidad de involucrar múltiples víctimas, confirmando que existen perfiles y dinámicas delictivas claramente diferenciados entre ambos grupos.

La violencia se concentra geográficamente — el territorio es el factor determinante

Los departamentos de Valle del Cauca, Antioquia y Cundinamarca concentran más del 45% de los delitos registrados, superando ampliamente el comportamiento promedio del país. El análisis de varianza identificó a estos territorios con diferencias estadísticamente significativas en la cantidad de víctimas por hecho, y la regresión logística mostró que el promedio departamental multiplica por 43.6 veces la probabilidad de eventos de alto riesgo. La incidencia en el resto del país es considerablemente menor, y el perfil por género varía según la región, lo que sugiere que factores locales —sociales, institucionales o culturales— moldean la dinámica de la violencia.

El tiempo no determina la gravedad del hecho

No se encontró relación significativa entre la fecha de ocurrencia —año, mes o día— y la cantidad de víctimas por evento. La correlación entre año y magnitud del hecho fue

prácticamente nula (-0.13), y en los modelos predictivos el coeficiente asociado al tiempo resultó cercano a cero. Si se observa una tendencia leve a la reducción con el paso de los años, su magnitud es tan reducida que no se considera estadísticamente relevante. En consecuencia, el momento en que ocurre el delito no explica su gravedad.

**Síntesis:** factores locales y sociales, no temporales

En definitiva, los elementos que verdaderamente estructuran la dinámica delictiva analizada son quién comete el hecho (género), con qué medios (tipo de arma) y en qué región (departamento). El tiempo aparece como un factor secundario: la evolución anual no modifica sustancialmente la probabilidad de que un evento sea más o menos grave. Estos hallazgos orientan la intervención: las políticas de prevención y seguridad deberían priorizarse territorialmente, adaptándose a las dinámicas específicas de cada región, antes que a cronogramas generales.

**Archivo:** [Notebook](#)

Se recomienda abrir el enlace en una cuenta de Google para poder ejecutar los bloques de código.

## Referencias

- bsginstitute. (23 de Agosto de 2026). *bsginstitute.com*. Obtenido de proceso-seleccion.bsginstitute.com: <https://proceso-seleccion.bsginstitute.com/bs-campus/blog/Dominando-Modelos-de-Probabilidad-en-Ciencia-de-Datos-1337>
- Edu.mx. (s.f.). *Correlación de variables*. Obtenido de belver.clavijero.edu.mx: [https://belver.clavijero.edu.mx/cursos/nme/semestre5/probyest\\_1/s4/contenidos/index.html](https://belver.clavijero.edu.mx/cursos/nme/semestre5/probyest_1/s4/contenidos/index.html)
- Fernández, O. (30 de septiembre de 2023). *El DataFrame: Fundamentos del Análisis de Datos*. Obtenido de Aprender BIG DATA: <https://aprenderbigdata.com/dataframe/>
- IBM.com. (15 de Abril de 2025). *Ibm.com*. Obtenido de <https://www.ibm.com/mx-es/think/topics/exploratory-data-analysis>.
- Institute, B. (26 de Agosto de 2026). *BSG Institute*. Obtenido de BSG Institute.: <https://proceso-seleccion.bsginstitute.com/bs-campus/blog/Dominando-Modelos-de-Probabilidad-en-Ciencia-de-Datos-1337>
- Institute, B. (23 de Agosto de 2026). *proceso-seleccion.bsginstitute.com*. Obtenido de proceso-seleccion.bsginstitute.com: <https://proceso-seleccion.bsginstitute.com/bs-campus/blog/Dominando-Modelos-de-Probabilidad-en-Ciencia-de-Datos-1337>